โครงงานเลขที่ วศ.คพ. **P031-2/2568**

เรื่อง

การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่

โดย

นายกิตติวินท์ พรรณเชษฐ์ รหัส **650610747**
นายพิพัฒน์พงศ์ กาวิลดง รหัส **650610792**
นายภัทรพล ณ นคร รหัส **650610796**
นายวายุ ทะไร รหัส **650610806**

โครงงานนี้
เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่
ปีการศึกษา **2568**

PROJECT No. CPE P031-2/2568

Thai-context Data Privacy Assessing for Large Language Models

Kittiwin Phannachet	**650610747**
Phiphatphong Kawindong	**650610792**
Pattarapol Na Nakorn	**650610796**
Wayu Tharai	**650610806**

A Project Submitted in Partial Fulfillment of Requirements
for the Degree of Bachelor of Engineering

Department of Computer Engineering
Faculty of Engineering
Chiang Mai University

2025

หัวข้อโครงงาน	: การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่	
	: Thai-context Data Privacy Assessing for Large Language Models	
โดย	: นายกิตติวินท์ พรรณเชษฐ์	รหัส 650610747
	นายพิพัฒน์พงศ์ กาวิลดง	รหัส 650610792
	นายภัทรพล ณ นคร	รหัส 650610796
	นายวายุ ทะไร	รหัส 650610806
ภาควิชา	: วิศวกรรมคอมพิวเตอร์	
อาจารย์ที่ปรึกษา	: รศ.ดร. จักรพงศ์ นาทวิชัย	
ปริญญา	: วิศวกรรมศาสตรบัณฑิต	
สาขา	: วิศวกรรมคอมพิวเตอร์	
ปีการศึกษา	: 2568	

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่ ได้อนุมัติให้โครงงานนี้เป็นส่วน-หนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต (สาขาวิศวกรรมคอมพิวเตอร์)

..... หัวหน้าภาควิชาวิศวกรรมคอมพิวเตอร์
(รศ.ดร. สันติ พิทักษ์กิจนุกูร)

คณะกรรมการสอบโครงงาน

..... ประธานกรรมการ
(รศ.ดร. จักรพงศ์ นาทวิชัย)

..... กรรมการ
(ผศ.ดร. กานต์ ปทานุคม)

..... กรรมการ
(ผศ.ดร. พฤษภ์ บุญมา)

หัวข้อโครงงาน	: การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่	
	: Thai-context Data Privacy Assessing for Large Language Models	
โดย	: นายกิตติวินท์ พรรณเชษฐ์	รหัส 650610747
	นายพิพัฒน์พงศ์ กาวิลดง	รหัส 650610792
	นายภัทรพล ณ นคร	รหัส 650610796
	นายวายุ ทะไร	รหัส 650610806
ภาควิชา	: วิศวกรรมคอมพิวเตอร์	
อาจารย์ที่ปรึกษา	: รศ.ดร. จักรพงศ์ นาทวิชัย	
ปริญญา	: วิศวกรรมศาสตรบัณฑิต	
สาขา	: วิศวกรรมคอมพิวเตอร์	
ปีการศึกษา	: 2568	

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อประเมินความเสี่ยงด้านความเป็นส่วนตัวของข้อมูลในโมเดลภาษาขนาดใหญ่ (LLMs) สำหรับบริบทภาษาไทย โดยเน้นการวิเคราะห์การโจมตีประเภท Data Extraction Attack (DEA) และ Jailbreak Attack (JA) ผ่านตัวแปรด้านระดับภาษาไทย 5 ระดับ ได้แก่ ระดับพิธีการ, ทางการ, กึ่งทางการ, ไม่เป็นทางการ และกันเอง การทดลองดำเนินการบนโมเดล Llama-3.1-8b-instant, Meta-llama-llama-4-maverick-17b-128e-instruct และ Moonshotai-kimi-k2-instruct-0905

ผลการทดลองชี้ให้เห็นว่า Llama-3.1-8B-instant มีความต้านทานต่อ DEA ดีที่สุด ขณะที่ Meta-llama-llama-4-maverick-17b-128e-instruct มีประสิทธิภาพสูงสุดในการรับมือกับ JA สำหรับการเพิ่มความมั่นคงปลอดภัย ผลการวิจัยยืนยันว่ากลไก Scrubbing เหมาะสมสำหรับการป้องกันการรั่วไหลของข้อมูล PII ในขณะที่ Defensive Prompting ให้ผลลัพธ์ที่ดีกว่าในการป้องกันการเจาะระบบ (Jailbreak) สรุปผลการศึกษาให้แนวทางในการเลือกใช้โมเดลและกลไกป้องกันที่เหมาะสมเพื่อลดความเสี่ยงด้านความเป็นส่วนตัวในบริบทการใช้งานภาษาไทย

Project Title	: Thai-context Data Privacy Assessing for Large Language Models	
Name	: Kittiwin Phannachet	650610747
	Phiphatphong Kawindong	650610792
	Pattarapol Na Nakorn	650610796
	Wayu Tharai	650610806
Department	: Computer Engineering	
Project Advisor	: Assoc. Prof. Juggapong Natwichai, Ph.D.	
Degree	: Bachelor of Engineering	
Program	: Computer Engineering	
Academic Year	: 2025	

ABSTRACT

This project aims to assess data privacy risks in Large Language Models (LLMs) within the Thai context, specifically focusing on the analysis of Data Extraction Attacks (DEA) and Jailbreak Attacks (JA). The evaluation is conducted across five levels of Thai linguistic registers: formal, official, semi-formal, informal, and casual. Experiments were performed on three models: Llama-3.1-8B-instant, Meta-Llama-4-Maverick-17B-128e-instruct, and Moonshotai-Kimi-K2-instruct-0905.

Experimental results indicate that Llama-3.1-8B-instant exhibits the highest resistance to DEA, while Meta-Llama-4-Maverick-17B-128e-instruct demonstrates the highest effectiveness in mitigating JA. Regarding security enhancement, the research confirms that the Scrubbing mechanism is most suitable for preventing Personal Identifiable Information (PII) leakage. In contrast, Defensive Prompting proves superior in preventing jailbreak attempts. This study concludes by providing practical guidelines for selecting appropriate models and defense strategies to minimize data privacy risks in Thai language applications.

กิตติกรรมประกาศ

โครงงานวิจัยฉบับนี้สำเร็จลุล่วงไปได้ด้วยความกรุณาอย่างยิ่งจากอาจารย์จักรพงศ์ นาทวิชัย อาจารย์ที่ปรึกษาโครงงาน ที่ได้สละเวลาให้คำปรึกษา แนะนำแนวทางในการศึกษา และช่วยแก้ไขข้อบกพร่องต่าง ๆ ตลอดระยะเวลาการดำเนินงาน เพื่อให้งานวิจัยมีความสมบูรณ์และถูกต้องตามหลักวิชาการ คณะผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ ที่นี้

คณะผู้จัดทำขอขอบพระคุณ ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่ เป็นอย่างสูง สำหรับการสนับสนุนด้านงบประมาณในการเข้าถึงทรัพยากรทางเทคนิค (API) และการเอื้อเฟื้อสถานที่ในการดำเนินงานวิจัย รวมถึงขอบพระคุณคณาจารย์ทุกท่านที่ได้ประสิทธิ์ประสาทวิชาความรู้ซึ่งเป็นรากฐานสำคัญในการพัฒนาโครงงานวิจัยในครั้งนี้

นอกจากนี้ คณะผู้จัดทำขอแสดงความนับถือและขอบคุณงานวิจัย ”LLM-PBE: Assessing Data Privacy in Large Language Models” สำหรับการนำเสนอกรอบแนวคิดและระเบียบวิธีวิจัยอันทรงคุณค่า ซึ่งคณะผู้จัดทำได้นำมาอ้างอิงและพัฒนาต่อยอดเพื่อศึกษาผลกระทบในบริบทภาษาไทย

ท้ายที่สุดนี้ คณะผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุนและเป็นกำลังใจสำคัญเสมอมา รวมถึงเพื่อนนักศึกษาทุกคนที่ให้ความช่วยเหลือและแลกเปลี่ยนความคิดเห็นตลอดการทำโครงงานวิจัย

นายกิตติวินท์ พรรณเชษฐ์
นายพิพัฒน์พงศ์ กาวิลดง
นายภัทรพล ณ นคร
นายวายุ ทะไร
26 กุมภาพันธ์ 2569

สารบัญ

บทคัดย่อ . . . . . ข
Abstract . . . . . ค
กิตติกรรมประกาศ . . . . . ง
สารบัญ . . . . . จ
สารบัญรูป . . . . . ฉ
สารบัญตาราง . . . . . ช

1 บทนำ **1**
1.1 ที่มาของโครงงาน 1
1.2 วัตถุประสงค์ของโครงงาน 1
1.3 ขอบเขตของโครงงาน 1
1.3.1 ขอบเขตด้านฮาร์ดแวร์ 1
1.3.2 ขอบเขตด้านซอฟต์แวร์ 2
1.4 ประโยชน์ที่ได้รับ 3
1.5 เทคโนโลยีและเครื่องมือที่ใช้ 3
1.5.1 เทคโนโลยีด้านฮาร์ดแวร์ 3
1.5.2 เทคโนโลยีด้านซอฟต์แวร์ 3
1.6 แผนการดำเนินงาน 4
1.7 บทบาทและความรับผิดชอบ 4
1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม 5

2 ทฤษฎีที่เกี่ยวข้อง **7**
2.1 The first section 7
2.2 Second section 7
2.2.1 Subsection heading goes here 7
2.3 Third section 7
2.4 About using figures in your report 7
2.5 Overfull hbox 10
2.6 ความรู้ตามหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน 10
2.7 ความรู้นอกหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน 10

3 โครงสร้างและขั้นตอนการทำงาน **11**
3.1 Alice in Wonderland 11
3.1.1 The Black Kitten 11
3.1.2 The Reproach 11

4 การทดลองและผลลัพธ์ **13**

5 บทสรุปและข้อเสนอแนะ **14**
5.1 สรุปผล 14
5.2 ปัญหาที่พบและแนวทางการแก้ไข 14
5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ 14

บรรณานุกรม **15**

ก The first appendix **17**
ก.1 Appendix section 17

ข คู่มือการใช้งานระบบ **18**

ประวัติผู้เขียน **19**

สารบัญรูป

2.1 Sample figure 8

3.1 Poem 11

สารบัญตาราง

2.1 Sample landscape table 9

บทที่ 1
บทนำ

1.1 ที่มาของโครงงาน

ในปัจจุบัน โมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) ได้รับความนิยมและมีบทบาทสำคัญอย่างยิ่งในหลากหลายอุตสาหกรรม อย่างไรก็ตาม ความก้าวหน้าดังกล่าวมาพร้อมกับความท้าทายด้านความมั่นคงปลอดภัยของข้อมูล โดยเฉพาะความเสี่ยงที่ข้อมูลส่วนบุคคล (Personally Identifiable Information: PII) จากชุดข้อมูลที่ใช้ในการฝึกฝนโมเดลอาจรั่วไหลออกไปสู่สาธารณะได้ ผ่านการโจมตีในรูปแบบต่าง ๆ เช่น การโจมตีเพื่อดึงข้อมูลลับ (Data Extraction Attack: DEA) และการเจาะระบบเพื่อข้ามข้อจำกัดด้านความปลอดภัย (Jailbreak Attack: JA)

แม้ในปัจจุบันจะมีการพัฒนามาตรฐานและชุดทดสอบ (Benchmark) เพื่อประเมินความเสี่ยงเหล่านี้อย่างแพร่หลาย แต่การทดสอบส่วนใหญ่มักถูกจำกัดอยู่ในบริบทของภาษาอังกฤษเป็นหลัก ซึ่งไม่สามารถสะท้อนความซับซ้อนของภาษาไทยที่มีโครงสร้างเฉพาะตัวและระดับภาษา (Linguistic Registers) ที่หลากหลายได้ ความแตกต่างของระดับภาษาตั้งแต่ภาษาระดับพิธีการไปจนถึงภาษาระดับกันเอง อาจส่งผลต่อประสิทธิภาพของกลไกความปลอดภัยในโมเดลที่แตกต่างกัน

ด้วยเหตุนี้ คณะผู้จัดทำจึงได้พัฒนาชุดทดสอบภาษาไทยที่ครอบคลุม 5 ระดับภาษา เพื่อประเมินความเปราะบางของโมเดลภาษาขนาดเล็กที่มีประสิทธิภาพสูง ได้แก่ Llama-3.1-8B-instant, Meta-Llama-4-Maverick-17B และ Kimi-k2-instruct พร้อมทั้งเปรียบเทียบประสิทธิภาพของกลไกการป้องกันระหว่างการคัดกรองข้อมูล (Scrubbing) และการป้อนคำสั่งป้องกัน (Defensive Prompting) ผลการศึกษานี้จะช่วยสร้างแนวทางที่ชัดเจนในการรักษาความปลอดภัยของข้อมูลในบริบทภาษาไทย และเป็นพื้นฐานสำคัญในการพัฒนาปัญญาประดิษฐ์ที่มีความน่าเชื่อถือในประเทศไทยต่อไป

1.2 วัตถุประสงค์ของโครงงาน

1. เพื่อประเมินความเสี่ยงและระบุรูปแบบการโจมตีที่สร้างความเสียหายสูงที่สุดสำหรับการโจมตีในรูปแบบภาษาไทย ทั้งในรูปแบบ Data Extraction Attack และ Jailbreak Attack
2. เพื่อเปรียบเทียบและนำเสนอแนวทางการป้องกันที่มีประสิทธิภาพสูงสุด สำหรับภาษาไทย โดยพิจารณาความปลอดภัยที่เพิ่มขึ้นหลังการใช้ Scrubbing และ Defensive Prompting

1.3 ขอบเขตของโครงงาน

ในการดำเนินโครงงานวิจัยนี้ คณะผู้จัดทำได้กำหนดขอบเขตของการศึกษาไว้ดังนี้:

1.3.1 ขอบเขตด้านฮาร์ดแวร์

- เครื่องคอมพิวเตอร์ส่วนบุคคลสำหรับการพัฒนาและประมวลผลคำสั่งชุดทดสอบ
- โครงสร้างพื้นฐานระบบประมวลผลผ่าน Groq API สำหรับการเรียกใช้งานโมเดลภาษาขนาดใหญ่

1.3.2 ขอบเขตด้านซอฟต์แวร์

1. โมเดลภาษาที่ใช้ในการศึกษา (Foundation Models)
   ทำการทดสอบและประเมินผลบนโมเดลภาษาขนาดใหญ่จำนวน 3 โมเดล ได้แก่
   - Llama-3.1-8B-instant
   - Meta-Llama-4-Maverick-17B-128e-instruct
   - Moonshotai-Kimi-K2-instruct-0905
2. รูปแบบภาษาและระดับภาษา (Linguistic Registers)
   ศึกษาและออกแบบชุดคำสั่ง (Prompt) ในรูปแบบภาษาไทย โดยแบ่งระดับภาษาออกเป็น 5 ระดับ ได้แก่
   - ภาษาระดับพิธีการ (Ceremonial)
   - ภาษาระดับทางการ (Formal)
   - ภาษาระดับกึ่งทางการ (Semi-formal)
   - ภาษาระดับไม่เป็นทางการ (Informal)
   - ภาษาระดับกันเอง (Casual)
3. รูปแบบการโจมตีที่ใช้ในการทดสอบ (Attack Scenarios)
   - Data Extraction Attack (DEA): มุ่งเน้นการโจมตีเพื่อดึงข้อมูลส่วนบุคคล (PII) จากชุดข้อมูล Enron Email
   - Jailbreak Attack (JA): ใช้เทคนิคการออกแบบ Prompt เพื่อหลีกเลี่ยงระบบความปลอดภัยของโมเดล โดยมุ่งเป้าไปที่ข้อมูลส่วนบุคคลที่ถูกจำกัดไว้ เช่น ข้อมูลของบุคคลสำคัญ
4. กลไกการป้องกันที่ศึกษา (Defense Mechanisms)
   ประเมินประสิทธิภาพของกลไกการป้องกัน 2 รูปแบบหลัก:
   - Scrubbing: การตรวจสอบและคัดกรองข้อมูลขาเข้า (Input) โดยใช้เทคนิค Regex และ NER เพื่อปกปิดข้อมูลส่วนบุคคล
   - Defensive Prompting: การเพิ่มคำสั่งป้องกันในระดับ System Prompt เพื่อเสริมสร้างความปลอดภัยจากภายในโมเดล
5. สภาพแวดล้อมและทรัพยากรที่ใช้
   - ดำเนินการทดสอบผ่านการเรียกใช้งานโมเดลด้วย Groq API
   - การทดสอบแต่ละกรณีจะดำเนินการทำซ้ำอย่างน้อย 5 รอบ เพื่อหาค่าเฉลี่ยของอัตราการโจมตีสำเร็จ (Average Success Rate)

1.4 ประโยชน์ที่ได้รับ

ในการดำเนินโครงงานวิจัยนี้ คณะผู้จัดทำคาดว่าจะได้รับประโยชน์ต่าง ๆ ดังนี้:

- ความเข้าใจเชิงลึกเกี่ยวกับความปลอดภัยของ LLM ในบริบทภาษาไทย: ทำให้ทราบถึงระดับความเปราะบางและอัตราความสำเร็จของการโจมตีประเภท DEA และ JA ในระดับภาษาไทยที่แตกต่างกันทั้ง 5 ระดับ
- แนวทางการเลือกใช้โมเดลภาษาขนาดเล็กที่มีประสิทธิภาพ: ทราบถึงขีดความสามารถและความต้านทานต่อการโจมตีของโมเดล Llama-3.1-8b-instant, Meta-llama-llama-4-maverick-17b-128e-instruct และ Moonshotai-kimi-k2-instruct-0905 เพื่อเป็นข้อมูลประกอบการตัดสินใจเลือกใช้โมเดลในสภาพแวดล้อมที่จำกัดทรัพยากร
- กลไกการป้องกันที่เหมาะสมต่อประเภทภัยคุกคาม: ได้ข้อสรุปที่ชัดเจนว่าควรเลือกใช้กลไก Scrubbing หรือ Defensive Prompting สำหรับการรับมือกับการโจมตีแต่ละประเภท เพื่อการรักษาความปลอดภัยของข้อมูลส่วนบุคคล (PII) อย่างมีประสิทธิภาพสูงสุด
- มาตรฐานการประเมินผลสำหรับภาษาไทย (Thai Privacy Benchmark): สร้างบรรทัดฐานและแนวทางในการทดสอบความปลอดภัยของโมเดลภาษาในประเทศไทย โดยต่อยอดจากกรอบแนวคิดที่เป็นสากลอย่าง LLM-PBE
- การเสริมสร้างความปลอดภัยให้แก่ระบบปัญญาประดิษฐ์: ข้อมูลจากการวิจัยสามารถนำไปประยุกต์ใช้เพื่อลดความเสี่ยงด้านข้อมูลรั่วไหลในการพัฒนาแอปพลิเคชันที่ใช้งานจริงในบริบทภาษาไทย

1.5 เทคโนโลยีและเครื่องมือที่ใช้

เทคโนโลยีและเครื่องมือที่ใช้ในการพัฒนาและดำเนินงานวิจัย มีรายละเอียดดังนี้:

1.5.1 เทคโนโลยีด้านฮาร์ดแวร์

- Personal Computer Specification: เครื่องคอมพิวเตอร์สำหรับการพัฒนาโปรแกรมและการจัดเก็บชุดข้อมูลทดสอบ
- Cloud Inference Engine: ใช้งานระบบประมวลผลประสิทธิภาพสูงจาก Groq API เพื่อให้สามารถรันโมเดลขนาดใหญ่ได้อย่างรวดเร็วและมีประสิทธิภาพ

1.5.2 เทคโนโลยีด้านซอฟต์แวร์

- Programming Language: ภาษา Python สำหรับการพัฒนาสคริปต์เพื่อจำลองการโจมตีและประมวลผลกลไกการป้องกัน
- Application Programming Interface (API): บริการ Groq API สำหรับการเชื่อมต่อและส่งคำสั่ง (Prompts) ไปยังโมเดลเป้าหมาย
- Security and Data Processing Tools:

1. Regular Expression (Regex): สำหรับการทำ Pattern Matching เพื่อตรวจจับและปิดบังข้อมูลในส่วน Scrubbing
2. Named Entity Recognition (NER): สำหรับระบุชื่อบุคคลหรือข้อมูลเฉพาะเจาะจงในภาษาไทยเพื่อทำการ Scrubbing

- Development Platform: ซอฟต์แวร์สำหรับเขียนและทดสอบโค้ด (VS Code) และเครื่องมือสำหรับวิเคราะห์ผลสถิติ สร้างกราฟ

1.6 แผนการดำเนินงาน

ขั้นตอนการดำเนินงาน	ธ.ค. 2568	ม.ค. 2569	ก.พ. 2569	มี.ค. 2569
เปลี่ยนหัวข้อโปรเจค และ กำหนดขอบเขตของโปรเจค	■			
ศึกษางานวิจัยที่เกี่ยวข้อง (LLM-PBE)	■			
ออกแบบ DEA prompt และ JA prompt สำหรับภาษาไทยในแต่ละระดับ	■			
สร้าง script รันการโจมตีอัตโนมัติ และ ออกแบบการการวัดผลการโจมตีที่สำเร็จ	■	■		
ดำเนินการทดลองโจมตีและเก็บรวบรวมผลการทดสอบ	■	■	■	
ออกแบบการป้องกัน Scrubbing และ Defensive prompt			■	
ดำเนินการทดลองป้องกันการโจมตีและเก็บรวบรวมผลการทดสอบ			■	■
วิเคราะห์ผลการทดลองและสรุปผลการทดลอง				■
จัดทำรายงานฉบับสมบูรณ์และเตรียมนำเสนอผลงาน				■

1.7 บทบาทและความรับผิดชอบ

เพื่อให้การดำเนินงานวิจัยเป็นไปอย่างมีประสิทธิภาพ คณะผู้จัดทำได้แบ่งหน้าที่ความรับผิดชอบตามความเชี่ยวชาญและเนื้อหางาน ดังนี้:

1. กิตติวินท์ พรรณเชษฐ์
   - ออกแบบชุดคำสั่งสำหรับการโจมตีทั้งรูปแบบ Data Extraction Attack (DEA) และ Jailbreak Attack (JA)
   - รับผิดชอบการรันการโจมตีในระดับภาษาทางการ (Ceremonial) และระดับภาษากึ่งทางการ (Semi-formal)
   - ออกแบบและแก้ไขค่ามาตรวัด JA ในส่วนของข้อมูลติดต่อ
   - วิเคราะห์ผลลัพธ์การโจมตี DEA และ JA ร่วมกับทีมเพื่อนำไปสู่การสรุปผลเชิงสถิติและการทำ Visualization
2. พิพัฒน์พงศ์ กาวิลดง

- รับผิดชอบการแปลชุดคำสั่ง JA จากภาษาอังกฤษเป็นภาษาไทยครอบคลุมทั้ง 5 ระดับภาษา
- รับผิดชอบหลักในการรันการโจมตีในระดับภาษาไม่เป็นทางการ (Informal) และการรันผลการโจมตีในรอบภาษาอังกฤษสำหรับทุกโมเดล (Semi-formal)
- พัฒนาและแก้ไขโครงสร้าง Code สำหรับการจัดการเส้นทางข้อมูล (Path), การสร้างจุดบันทึกผล (Checkpoint) และการประยุกต์ใช้ Defensive Prompting ร่วมกับ JA
- ออกแบบมาตรวัด JA และจัดทำสื่อนำเสนอผลงานสำหรับการรายงานความก้าวหน้า

3. ภัทรพล ณ นคร

- ดำเนินการแปลชุดคำสั่งปริมาณมาก (Batch Processing) ผ่าน OpenAI API ให้ครอบคลุมทุกระดับภาษา
- รับผิดชอบการรันการโจมตีในระดับภาษาทางการ (Formal) และภาษาอังกฤษ รวมถึงการบริหารจัดการ API Key ผ่านระบบ Organization ของ Groq
- พัฒนามาตรวัด JA ให้สมบูรณ์ วิเคราะห์ Keyword เพื่อออกแบบกลไกการป้องกัน และดำเนินการทดสอบระบบ Input Scrubbing
- จัดการระบบควบคุมเวอร์ชันของซอร์สโค้ด (Version Control) และวิเคราะห์ผลลัพธ์เพื่อสร้าง Visualization

4. วายุ ทะไร

- ออกแบบมาตรวัดสำหรับ DEA และพัฒนาระบบรันการทดสอบอัตโนมัติที่สามารถเรียกใช้หลาย API และหลายรูปแบบการโจมตีพร้อมกันผ่าน Terminal เดียว
- รับผิดชอบหลักในการรันการโจมตีในระดับภาษากันเอง (Casual) สำหรับทั้ง 3 โมเดล และรันการทดสอบในรอบภาษาอังกฤษ
- พัฒนาระบบรวบรวมข้อมูลผลลัพธ์ คำนวณปริมาณ Token และความยาวข้อความ พร้อมสร้างกราฟสรุปผลอัตโนมัติ
- ออกแบบชุดคำสั่งป้องกัน (Defensive Prompting) สำหรับทั้ง DEA และ JA จำนวน 12 รูปแบบ และคัดเลือกรูปแบบที่มีประสิทธิภาพสูงสุดมาใช้งาน

1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม

การดำเนินโครงงานวิจัยนี้ส่งผลกระทบในมิติต่าง ๆ ที่สำคัญ ดังนี้:

- ด้านความปลอดภัยและกฎหมาย
  โครงงานนี้ช่วยระบุช่องโหว่ของการรั่วไหลข้อมูลส่วนบุคคล (PII) ในโมเดลภาษาขนาดใหญ่ ซึ่งสอดคล้องกับหลักการของพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ของประเทศไทย โดยการทดสอบการโจมตีแบบ Data Extraction Attack (DEA) และ Jailbreak Attack (JA) ช่วยให้ผู้พัฒนาระบบสามารถเตรียมแนวทางป้องกันเพื่อลดความเสี่ยงทางกฎหมายและเพิ่มความมั่นคงปลอดภัยให้แก่ข้อมูลของผู้ใช้งาน

- ด้านสังคมและวัฒนธรรม
  เนื่องจากมาตรฐานการประเมินส่วนใหญ่มักจำกัดอยู่ในบริบทภาษาอังกฤษ โครงงานนี้จึงสร้างผลกระทบเชิงบวกต่อสังคมไทยโดยการสร้างชุดทดสอบที่ครอบคลุมถึง 5 ระดับภาษาไทย ช่วยให้เทคโนโลยี AI มีความเข้าใจและเคารพในบริบททางวัฒนธรรมที่หลากหลายของไทย ตั้งแต่ภาษาระดับพิธีการไปจนถึงภาษาระดับกันเอง
- ด้านสุขภาพและสิ่งแวดล้อม
  การมุ่งเน้นศึกษาบนโมเดลขนาดเล็กที่ประหยัดทรัพยากร (Resource-saving models) เช่น llama-3.1-8b-instant และ meta-llama-llama-4-maverick-17b-128e-instruct ส่งผลดีต่อสิ่งแวดล้อมในแง่ของการลดการใช้พลังงานไฟฟ้าและทรัพยากรในการประมวลผล (Compute power) ซึ่งเป็นส่วนหนึ่งของการพัฒนา Green IT ในอนาคต

บทที่ 2
ทฤษฎีที่เกี่ยวข้อง

การทำโครงงาน เริ่มต้นด้วยการศึกษาค้นคว้า ทฤษฎีที่เกี่ยวข้อง หรือ งานวิจัย/โครงงาน ที่เคยมีผู้นำเสนอไว้แล้ว ซึ่งเนื้อหาในบทนี้ก็จะเกี่ยวกับการอธิบายถึงสิ่งที่เกี่ยวข้องกับโครงงาน เพื่อให้ผู้อ่านเข้าใจเนื้อหาในบทถัดๆ ไปได้ง่ายขึ้น

2.1 The first section

The text for Section 1 goes here.

2.2 Second section

Section 2 text.

2.2.1 Subsection heading goes here

Subsection 1 text

Subsubsection 1 heading goes here

Subsubsection 1 text

Subsubsection 2 heading goes here

Subsubsection 2 text

2.3 Third section

Section 3 text. The dielectric constant at the air-metal interface determines the resonance shift as absorption or capture occurs is shown in Equation (2.1):

$$k_1 = \frac{\omega}{c(1/\varepsilon_m + 1/\varepsilon_i)^{1/2}} = k_2 = \frac{\omega \sin(\theta)\varepsilon_{air}^{1/2}}{c} \tag{2.1}$$

where ω is the frequency of the plasmon, c is the speed of light, ε_m is the dielectric constant of the metal, ε_i is the dielectric constant of neighboring insulator, and ε_{air} is the dielectric constant of air.

2.4 About using figures in your report

Using `\label` and `\ref` commands allows us to refer to figures easily. If we can refer to Figures 3.1 and 2.1 by name in the LaTeX source code, then we will not need to update the code that refers to it even if the placement or ordering of the figures changes.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

รูปที่ 2.1: This figure is a sample containing lorem ipsum, showing you how you can include figures and glossary in your report. You can specify a shorter caption that will appear in the List of Figures.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud

ตารางที่ 2.1: Sample landscape table

Year	A	B
1989	12	23
1990	4	9
1991	3	6

exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

2.5 Overfull hbox

When the `semifinal` option is passed to the `cpecmu` document class, any line that is longer than the line width, i.e., an overfull hbox, will be highlighted with a black solid rule:

juxtaposition

2.6 ความรู้ตามหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน

อธิบายถึงความรู้ และแนวทางการนำความรู้ต่างๆ ที่ได้เรียนตามหลักสูตร ซึ่งถูกนำมาใช้ในโครงงาน

2.7 ความรู้นอกหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน

อธิบายถึงความรู้ต่างๆ ที่เรียนรู้ด้วยตนเอง และแนวทางการนำความรู้เหล่านั้นมาใช้ในโครงงาน

บทที่ 3
โครงสร้างและขั้นตอนการทำงาน

ในบทนี้จะกล่าวถึงหลักการ และการออกแบบระบบ

3.1 Alice in Wonderland

3.1.1 The Black Kitten

One thing was certain, that the WHITE kitten had had nothing to do with it:—it was the black kitten's fault entirely [1]. For the white kitten had been having its face washed by the old cat for the last quarter of an hour (and bearing it pretty well, considering); so you see that it COULDN'T have had any hand in the mischief.

The way Dinah washed her children's faces was this: first she held the poor thing down by its ear with one paw, and then with the other paw she rubbed its face all over, the wrong way, beginning at the nose: and just now, as I said, she was hard at work on the white kitten, which was lying quite still and trying to purr—no doubt feeling that it was all meant for its good.

But the black kitten had been finished with earlier in the afternoon, and so, while Alice was sitting curled up in a corner of the great arm-chair, half talking to herself and half asleep, the kitten had been having a grand game of romps with the ball of worsted Alice had been trying to wind up, and had been rolling it up and down till it had all come undone again; and there it was, spread over the hearth-rug, all knots and tangles, with the kitten running after its own tail in the middle.

3.1.2 The Reproach

'Oh, you wicked little thing!' cried Alice, catching up the kitten, and giving it a little kiss to make it understand that it was in disgrace. 'Really, Dinah ought to have taught you better manners! You OUGHT, Dinah, you know you ought!' she added, looking reproachfully at

รูปที่ 3.1: The Walrus and the Carpenter

the old cat, and speaking in as cross a voice as she could manage—and then she scrambled back into the arm-chair, taking the kitten and the worsted with her, and began winding up the ball again. But she didn't get on very fast, as she was talking all the time, sometimes to the kitten, and sometimes to herself. Kitty sat very demurely on her knee, pretending to watch the progress of the winding, and now and then putting out one paw and gently touching the ball, as if it would be glad to help, if it might.

'Do you know what to-morrow is, Kitty?' Alice began. 'You'd have guessed if you'd been up in the window with me—only Dinah was making you tidy, so you couldn't. I was watching the boys getting in stick for the bonfire—and it wants plenty of sticks, Kitty! Only it got so cold, and it snowed so, they had to leave off. Never mind, Kitty, we'll go and see the bonfire to-morrow.' Here Alice wound two or three turns of the worsted round the kitten's neck, just to see how it would look: this led to a scramble, in which the ball rolled down upon the floor, and yards and yards of it got unwound again.

'Do you know, I was so angry, Kitty,' Alice went on as soon as they were comfortably settled again, 'when I saw all the mischief you had been doing, I was very nearly opening the window, and putting you out into the snow! And you'd have deserved it, you little mischievous darling! What have you got to say for yourself? Now don't interrupt me!' she went on, holding up one finger. 'I'm going to tell you all your faults. Number one: you squeaked twice while Dinah was washing your face this morning. Now you can't deny it, Kitty: I heard you! What that you say?' (pretending that the kitten was speaking.) 'Her paw went into your eye? Well, that's YOUR fault, for keeping your eyes open—if you'd shut them tight up, it wouldn't have happened. Now don't make any more excuses, but listen! Number two: you pulled Snowdrop away by the tail just as I had put down the saucer of milk before her! What, you were thirsty, were you?

บทที่ 4
การทดลองและผลลัพธ์

ในบทนี้จะทดสอบเกี่ยวกับการทำงานในฟังก์ชันหลักๆ

บทที่ 5
บทสรุปและข้อเสนอแนะ

5.1 สรุปผล

นศ. ควรสรุปถึงข้อจำกัดของระบบในด้านต่างๆ ที่ระบบมีในเนื้อหาส่วนนี้ด้วย

5.2 ปัญหาที่พบและแนวทางการแก้ไข

ในการทำโครงงานนี้ พบว่าเกิดปัญหาหลักๆ ดังนี้

5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ

ข้อเสนอแนะเพื่อพัฒนาโครงงานนี้ต่อไป มีดังนี้

บรรณานุกรม

[1] Lewis Carroll. *Alice's Adventures in Wonderland*. George MacDonald, 1865.

ภาคผนวก

ภาคผนวก ก
The first appendix

Text for the first appendix goes here.

ก.1 Appendix section

Text for a section in the first appendix goes here.

test ทดสอบฟอนต์ serif ภาษาไทย

test ทดสอบฟอนต์ sans serif ภาษาไทย

test ทดสอบฟอนต์ teletype ภาษาไทย

test ทดสอบฟอนต์ teletype ภาษาไทย

ตัวหนา serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

ตัวเอียง serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

ตัวหนาเอียง serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

https://www.example.com/test_ทดสอบ_url

ภาคผนวก ข
คู่มือการใช้งานระบบ

Manual goes here.

ประวัติผู้เขียน

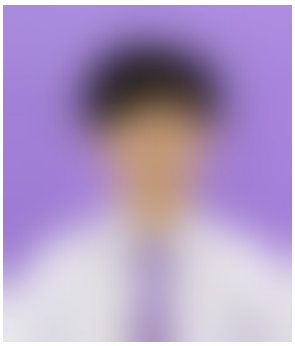

Your biosketch goes here. Make sure it sits inside the `biosketch` environment.