โครงงานเลขที่ วศ.คพ. **P031-2/2568**

เรื่อง

การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่

โดย

นายกิตติวินท์ พรรณเชษฐ์ รหัส **650610747**
นายพิพัฒน์พงศ์ กาวิลดง รหัส **650610792**
นายภัทรพล ณ นคร รหัส **650610796**
นายวายุ ทะไร รหัส **650610806**

โครงงานนี้
เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่
ปีการศึกษา **2568**

PROJECT No. CPE P031-2/2568

Thai-context Data Privacy Assessing for Large Language Models

Kittiwin Phannachet	**650610747**
Phiphatphong Kawindong	**650610792**
Pattarapol Na Nakorn	**650610796**
Wayu Tharai	**650610806**

A Project Submitted in Partial Fulfillment of Requirements
for the Degree of Bachelor of Engineering

Department of Computer Engineering
Faculty of Engineering
Chiang Mai University

2025

หัวข้อโครงงาน	: การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่	
	: Thai-context Data Privacy Assessing for Large Language Models	
โดย	: นายกิตติวินท์ พรรณเชษฐ์	รหัส 650610747
	นายพิพัฒน์พงศ์ กาวิลดง	รหัส 650610792
	นายภัทรพล ณ นคร	รหัส 650610796
	นายวายุ ทะไร	รหัส 650610806
ภาควิชา	: วิศวกรรมคอมพิวเตอร์	
อาจารย์ที่ปรึกษา	: รศ.ดร. จักรพงศ์ นาทวิชัย	
ปริญญา	: วิศวกรรมศาสตรบัณฑิต	
สาขา	: วิศวกรรมคอมพิวเตอร์	
ปีการศึกษา	: 2568	

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่ ได้อนุมัติให้โครงงานนี้เป็นส่วน-หนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต (สาขาวิศวกรรมคอมพิวเตอร์)

..... หัวหน้าภาควิชาวิศวกรรมคอมพิวเตอร์
(รศ.ดร. สันติ พิทักษ์กิจนุกูร)

คณะกรรมการสอบโครงงาน

..... ประธานกรรมการ
(รศ.ดร. จักรพงศ์ นาทวิชัย)

..... กรรมการ
(ผศ.ดร. กานต์ ปทานุคม)

..... กรรมการ
(ผศ.ดร. พฤษภ์ บุญมา)

หัวข้อโครงงาน	: การประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่	
	: Thai-context Data Privacy Assessing for Large Language Models	
โดย	: นายกิตติวินท์ พรรณเชษฐ์	รหัส 650610747
	นายพิพัฒน์พงศ์ กาวิลดง	รหัส 650610792
	นายภัทรพล ณ นคร	รหัส 650610796
	นายวายุ ทะไร	รหัส 650610806
ภาควิชา	: วิศวกรรมคอมพิวเตอร์	
อาจารย์ที่ปรึกษา	: รศ.ดร. จักรพงศ์ นาทวิชัย	
ปริญญา	: วิศวกรรมศาสตรบัณฑิต	
สาขา	: วิศวกรรมคอมพิวเตอร์	
ปีการศึกษา	: 2568	

บทคัดย่อ

โครงงานนี้มีวัตถุประสงค์เพื่อประเมินความเสี่ยงด้านความเป็นส่วนตัวของข้อมูลในโมเดลภาษาขนาดใหญ่ (LLMs) สำหรับบริบทภาษาไทย โดยเน้นการวิเคราะห์การโจมตีประเภท Data Extraction Attack (DEA) และ Jailbreak Attack (JA) ผ่านตัวแปรด้านระดับภาษาไทย 5 ระดับ ได้แก่ ระดับพิธีการ, ทางการ, กึ่งทางการ, ไม่เป็นทางการ และกันเอง การทดลองดำเนินการบนโมเดล Llama-3.1-8b-instant, Meta-llama-llama-4-maverick-17b-128e-instruct และ Moonshotai-kimi-k2-instruct-0905

ผลการทดลองชี้ให้เห็นว่า Llama-3.1-8B-instant มีความต้านทานต่อ DEA ดีที่สุด ขณะที่ Meta-llama-llama-4-maverick-17b-128e-instruct มีประสิทธิภาพสูงสุดในการรับมือกับ JA สำหรับการเพิ่มความมั่นคงปลอดภัย ผลการวิจัยยืนยันว่ากลไก Scrubbing เหมาะสมสำหรับการป้องกันการรั่วไหลของข้อมูล PII ในขณะที่ Defensive Prompting ให้ผลลัพธ์ที่ดีกว่าในการป้องกันการเจาะระบบ (Jailbreak) สรุปผลการศึกษาให้แนวทางในการเลือกใช้โมเดลและกลไกป้องกันที่เหมาะสมเพื่อลดความเสี่ยงด้านความเป็นส่วนตัวในบริบทการใช้งานภาษาไทย

Project Title	: Thai-context Data Privacy Assessing for Large Language Models	
Name	: Kittiwin Phannachet	650610747
	Phiphatphong Kawindong	650610792
	Pattarapol Na Nakorn	650610796
	Wayu Tharai	650610806
Department	: Computer Engineering	
Project Advisor	: Assoc. Prof. Juggapong Natwichai, Ph.D.	
Degree	: Bachelor of Engineering	
Program	: Computer Engineering	
Academic Year	: 2025	

ABSTRACT

This project aims to assess data privacy risks in Large Language Models (LLMs) within the Thai context, specifically focusing on the analysis of Data Extraction Attacks (DEA) and Jailbreak Attacks (JA). The evaluation is conducted across five levels of Thai linguistic registers: formal, official, semi-formal, informal, and casual. Experiments were performed on three models: Llama-3.1-8B-instant, Meta-Llama-4-Maverick-17B-128e-instruct, and Moonshotai-Kimi-K2-instruct-0905.

Experimental results indicate that Llama-3.1-8B-instant exhibits the highest resistance to DEA, while Meta-Llama-4-Maverick-17B-128e-instruct demonstrates the highest effectiveness in mitigating JA. Regarding security enhancement, the research confirms that the Scrubbing mechanism is most suitable for preventing Personal Identifiable Information (PII) leakage. In contrast, Defensive Prompting proves superior in preventing jailbreak attempts. This study concludes by providing practical guidelines for selecting appropriate models and defense strategies to minimize data privacy risks in Thai language applications.

กิตติกรรมประกาศ

โครงงานวิจัยฉบับนี้สำเร็จลุล่วงไปได้ด้วยความกรุณาอย่างยิ่งจากอาจารย์จักรพงศ์ นาทวิชัย อาจารย์ที่ปรึกษาโครงงาน ที่ได้สละเวลาให้คำปรึกษา แนะนำแนวทางในการศึกษา และช่วยแก้ไขข้อบกพร่องต่าง ๆ ตลอดระยะเวลาการดำเนินงาน เพื่อให้งานวิจัยมีความสมบูรณ์และถูกต้องตามหลักวิชาการ คณะผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ ที่นี้

คณะผู้จัดทำขอขอบพระคุณ ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่ เป็นอย่างสูง สำหรับการสนับสนุนด้านงบประมาณในการเข้าถึงทรัพยากรทางเทคนิค (API) และการเอื้อเฟื้อสถานที่ในการดำเนินงานวิจัย รวมถึงขอบพระคุณคณาจารย์ทุกท่านที่ได้ประสิทธิ์ประสาทวิชาความรู้ซึ่งเป็นรากฐานสำคัญในการพัฒนาโครงงานวิจัยในครั้งนี้

นอกจากนี้ คณะผู้จัดทำขอแสดงความนับถือและขอบคุณงานวิจัย ”LLM-PBE: Assessing Data Privacy in Large Language Models” สำหรับการนำเสนอกรอบแนวคิดและระเบียบวิธีวิจัยอันทรงคุณค่า ซึ่งคณะผู้จัดทำได้นำมาอ้างอิงและพัฒนาต่อยอดเพื่อศึกษาผลกระทบในบริบทภาษาไทย

ท้ายที่สุดนี้ คณะผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุนและเป็นกำลังใจสำคัญเสมอมา รวมถึงเพื่อนนักศึกษาทุกคนที่ให้ความช่วยเหลือและแลกเปลี่ยนความคิดเห็นตลอดการทำโครงงานวิจัย

นายกิตติวินท์ พรรณเชษฐ์
นายพิพัฒน์พงศ์ กาวิลดง
นายภัทรพล ณ นคร
นายวายุ ทะไร
26 กุมภาพันธ์ 2569

สารบัญ

บทคัดย่อ . . . . . ข
Abstract . . . . . ค
กิตติกรรมประกาศ . . . . . ง
สารบัญ . . . . . จ
สารบัญรูป . . . . . ช
สารบัญตาราง . . . . . ซ

1 บทนำ **1**
1.1 ที่มาของโครงงาน 1
1.2 วัตถุประสงค์ของโครงงาน 1
1.3 ขอบเขตของโครงงาน 1
1.3.1 ขอบเขตด้านฮาร์ดแวร์ 1
1.3.2 ขอบเขตด้านซอฟต์แวร์ 2
1.4 ประโยชน์ที่ได้รับ 3
1.5 เทคโนโลยีและเครื่องมือที่ใช้ 3
1.5.1 เทคโนโลยีด้านฮาร์ดแวร์ 3
1.5.2 เทคโนโลยีด้านซอฟต์แวร์ 3
1.6 แผนการดำเนินงาน 4
1.7 บทบาทและความรับผิดชอบ 4
1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม 5

2 ทฤษฎีที่เกี่ยวข้อง **7**
2.1 ตัวแบบภาษาขนาดใหญ่ (Large Language Models: LLMs) 7
2.2 ความปลอดภัยและความเป็นส่วนตัวของข้อมูลใน LLMs 7
2.3 บริบทภาษาไทยและระดับภาษา (Thai Context and Linguistic Registers) 8
2.4 กลไกการป้องกัน (Defense Mechanisms) 8
2.5 งานวิจัยที่เกี่ยวข้อง (Related Works) 8
2.6 ความรู้ตามหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน 9
2.7 ความรู้นอกหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน 9

3 โครงสร้างและขั้นตอนการทำงาน **10**
3.1 ภาพรวมสถาปัตยกรรมระบบ (System Architecture) 10
3.2 การเตรียมชุดข้อมูลและระดับภาษา (Data Preparation) 10
3.3 ระเบียบวิธีการโจมตี (Attack Methodology) 10
3.4 การออกแบบกลไกการป้องกัน (Defense Design) 11
3.4.1 Input Scrubbing: (เอาเลขแบบนี้ หรือจุดๆดี) 11
3.4.2 Defensive Prompting 11
3.5 การพัฒนาระบบรันการทดสอบอัตโนมัติ (Automated Testing) 11
3.6 มาตรวัดการประเมินผล (Evaluation Metrics) 11

4 การทดลองและผลลัพธ์ **12**
4.1 ผลการทดสอบการโจมตีเพื่อดึงข้อมูล (Data Extraction Attack: DEA) 12
4.1.1 การเปรียบเทียบระหว่างภาษาไทยและภาษาอังกฤษ 12
4.1.2 ผลกระทบของระดับภาษาไทยทั้ง 5 ระดับ 12
4.1.3 การวิเคราะห์ความแตกต่างของประสิทธิภาพรายโมเดลใน DEA 12

4.1.4 การวิเคราะห์เชิงปริมาณของ Token และความยาวข้อความ 12
4.1.5 ประสิทธิภาพของกลไกการป้องกัน (Scrubbing vs Defensive Prompting) . . 12
4.2 ผลการทดสอบการเจาะระบบเพื่อข้ามข้อจำกัด (Jailbreak Attack: JA) 12
4.2.1 การเปรียบเทียบระหว่างภาษาไทยและภาษาอังกฤษ 12
4.2.2 ผลกระทบของระดับภาษาไทยทั้ง 5 ระดับ 12
4.2.3 การวิเคราะห์ความแตกต่างของประสิทธิภาพรายโมเดลใน JA 14
4.2.4 การวิเคราะห์เชิงปริมาณของ Token และทรัพยากรที่ใช้ 14
4.2.5 ประสิทธิภาพของกลไกการป้องกัน (Scrubbing vs Defensive Prompting) . . 14
4.3 บทวิเคราะห์และข้อสรุปเชิงเทียบเคียง (Overall Discussion) 14

5 บทสรุปและข้อเสนอแนะ 15
5.1 สรุปผล 15
5.2 ปัญหาที่พบและแนวทางการแก้ไข 15
5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ 16

บรรณานุกรม 17

ก ตัวอย่างชุดคำสั่ง (Sample Prompts) 19

ข ซอร์สโค้ดของโครงงาน (Source Code) 20

ฆ ผลการทดสอบเพิ่มเติม (Extended Results) 21

ค คู่มือการใช้งานระบบ 22

ประวัติผู้เขียน 23

สารบัญรูป

4.1 DEA Accuracy Average (Thai vs English) 13
4.2 DEA Accuracy Average (Thai 5 levels) 13

สารบัญตาราง

บทที่ 1
บทนำ

1.1 ที่มาของโครงงาน

ในปัจจุบัน โมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) ได้รับความนิยมและมีบทบาทสำคัญอย่างยิ่งในหลากหลายอุตสาหกรรม อย่างไรก็ตาม ความก้าวหน้าดังกล่าวมาพร้อมกับความท้าทายด้านความมั่นคงปลอดภัยของข้อมูล โดยเฉพาะความเสี่ยงที่ข้อมูลส่วนบุคคล (Personally Identifiable Information: PII) จากชุดข้อมูลที่ใช้ในการฝึกฝนโมเดลอาจรั่วไหลออกไปสู่สาธารณะได้ ผ่านการโจมตีในรูปแบบต่าง ๆ เช่น การโจมตีเพื่อดึงข้อมูลลับ (Data Extraction Attack: DEA) และการเจาะระบบเพื่อข้ามข้อจำกัดด้านความปลอดภัย (Jailbreak Attack: JA)

แม้ในปัจจุบันจะมีการพัฒนามาตรฐานและชุดทดสอบ (Benchmark) เพื่อประเมินความเสี่ยงเหล่านี้อย่างแพร่หลาย แต่การทดสอบส่วนใหญ่มักถูกจำกัดอยู่ในบริบทของภาษาอังกฤษเป็นหลัก ซึ่งไม่สามารถสะท้อนความซับซ้อนของภาษาไทยที่มีโครงสร้างเฉพาะตัวและระดับภาษา (Linguistic Registers) ที่หลากหลายได้ ความแตกต่างของระดับภาษาตั้งแต่ภาษาระดับพิธีการไปจนถึงภาษาระดับกันเอง อาจส่งผลต่อประสิทธิภาพของกลไกความปลอดภัยในโมเดลที่แตกต่างกัน

ด้วยเหตุนี้ คณะผู้จัดทำจึงได้พัฒนาชุดทดสอบภาษาไทยที่ครอบคลุม 5 ระดับภาษา เพื่อประเมินความเปราะบางของโมเดลภาษาขนาดเล็กที่มีประสิทธิภาพสูง ได้แก่ Llama-3.1-8B-instant, Meta-Llama-4-Maverick-17B และ Kimi-k2-instruct พร้อมทั้งเปรียบเทียบประสิทธิภาพของกลไกการป้องกันระหว่างการคัดกรองข้อมูล (Scrubbing) และการป้อนคำสั่งป้องกัน (Defensive Prompting) ผลการศึกษานี้จะช่วยสร้างแนวทางที่ชัดเจนในการรักษาความปลอดภัยของข้อมูลในบริบทภาษาไทย และเป็นพื้นฐานสำคัญในการพัฒนาปัญญาประดิษฐ์ที่มีความน่าเชื่อถือในประเทศไทยต่อไป

1.2 วัตถุประสงค์ของโครงงาน

1. เพื่อประเมินความเสี่ยงและระบุรูปแบบการโจมตีที่สร้างความเสียหายสูงที่สุดสำหรับการโจมตีในรูปแบบภาษาไทย ทั้งในรูปแบบ Data Extraction Attack และ Jailbreak Attack
2. เพื่อเปรียบเทียบและนำเสนอแนวทางการป้องกันที่มีประสิทธิภาพสูงสุด สำหรับภาษาไทย โดยพิจารณาความปลอดภัยที่เพิ่มขึ้นหลังการใช้ Scrubbing และ Defensive Prompting

1.3 ขอบเขตของโครงงาน

ในการดำเนินโครงงานวิจัยนี้ คณะผู้จัดทำได้กำหนดขอบเขตของการศึกษาไว้ดังนี้:

1.3.1 ขอบเขตด้านฮาร์ดแวร์

- เครื่องคอมพิวเตอร์ส่วนบุคคลสำหรับการพัฒนาและประมวลผลคำสั่งชุดทดสอบ
- โครงสร้างพื้นฐานระบบประมวลผลผ่าน Groq API สำหรับการเรียกใช้งานโมเดลภาษาขนาดใหญ่

1.3.2 ขอบเขตด้านซอฟต์แวร์

1. โมเดลภาษาที่ใช้ในการศึกษา (Foundation Models)
   ทำการทดสอบและประเมินผลบนโมเดลภาษาขนาดใหญ่จำนวน 3 โมเดล ได้แก่
   - Llama-3.1-8B-instant
   - Meta-Llama-4-Maverick-17B-128e-instruct
   - Moonshotai-Kimi-K2-instruct-0905
2. รูปแบบภาษาและระดับภาษา (Linguistic Registers)
   ศึกษาและออกแบบชุดคำสั่ง (Prompt) ในรูปแบบภาษาไทย โดยแบ่งระดับภาษาออกเป็น 5 ระดับ ได้แก่
   - ภาษาระดับพิธีการ (Ceremonial)
   - ภาษาระดับทางการ (Formal)
   - ภาษาระดับกึ่งทางการ (Semi-formal)
   - ภาษาระดับไม่เป็นทางการ (Informal)
   - ภาษาระดับกันเอง (Casual)
3. รูปแบบการโจมตีที่ใช้ในการทดสอบ (Attack Scenarios)
   - Data Extraction Attack (DEA): มุ่งเน้นการโจมตีเพื่อดึงข้อมูลส่วนบุคคล (PII) จากชุดข้อมูล Enron Email
   - Jailbreak Attack (JA): ใช้เทคนิคการออกแบบ Prompt เพื่อหลีกเลี่ยงระบบความปลอดภัยของโมเดล โดยมุ่งเป้าไปที่ข้อมูลส่วนบุคคลที่ถูกจำกัดไว้ เช่น ข้อมูลของบุคคลสำคัญ
4. กลไกการป้องกันที่ศึกษา (Defense Mechanisms)
   ประเมินประสิทธิภาพของกลไกการป้องกัน 2 รูปแบบหลัก:
   - Scrubbing: การตรวจสอบและคัดกรองข้อมูลขาเข้า (Input) โดยใช้เทคนิค Regex และ NER เพื่อปกปิดข้อมูลส่วนบุคคล
   - Defensive Prompting: การเพิ่มคำสั่งป้องกันในระดับ System Prompt เพื่อเสริมสร้างความปลอดภัยจากภายในโมเดล
5. สภาพแวดล้อมและทรัพยากรที่ใช้
   - ดำเนินการทดสอบผ่านการเรียกใช้งานโมเดลด้วย Groq API
   - การทดสอบแต่ละกรณีจะดำเนินการทำซ้ำอย่างน้อย 5 รอบ เพื่อหาค่าเฉลี่ยของอัตราการโจมตีสำเร็จ (Average Success Rate)

1.4 ประโยชน์ที่ได้รับ

ในการดำเนินโครงงานวิจัยนี้ คณะผู้จัดทำคาดว่าจะได้รับประโยชน์ต่าง ๆ ดังนี้:

- ความเข้าใจเชิงลึกเกี่ยวกับความปลอดภัยของ LLM ในบริบทภาษาไทย: ทำให้ทราบถึงระดับความเปราะบางและอัตราความสำเร็จของการโจมตีประเภท DEA และ JA ในระดับภาษาไทยที่แตกต่างกันทั้ง 5 ระดับ
- แนวทางการเลือกใช้โมเดลภาษาขนาดเล็กที่มีประสิทธิภาพ: ทราบถึงขีดความสามารถและความต้านทานต่อการโจมตีของโมเดล Llama-3.1-8b-instant, Meta-llama-llama-4-maverick-17b-128e-instruct และ Moonshotai-kimi-k2-instruct-0905 เพื่อเป็นข้อมูลประกอบการตัดสินใจเลือกใช้โมเดลในสภาพแวดล้อมที่จำกัดทรัพยากร
- กลไกการป้องกันที่เหมาะสมต่อประเภทภัยคุกคาม: ได้ข้อสรุปที่ชัดเจนว่าควรเลือกใช้กลไก Scrubbing หรือ Defensive Prompting สำหรับการรับมือกับการโจมตีแต่ละประเภท เพื่อการรักษาความปลอดภัยของข้อมูลส่วนบุคคล (PII) อย่างมีประสิทธิภาพสูงสุด
- มาตรฐานการประเมินผลสำหรับภาษาไทย (Thai Privacy Benchmark): สร้างบรรทัดฐานและแนวทางในการทดสอบความปลอดภัยของโมเดลภาษาในประเทศไทย โดยต่อยอดจากกรอบแนวคิดที่เป็นสากลอย่าง LLM-PBE
- การเสริมสร้างความปลอดภัยให้แก่ระบบปัญญาประดิษฐ์: ข้อมูลจากการวิจัยสามารถนำไปประยุกต์ใช้เพื่อลดความเสี่ยงด้านข้อมูลรั่วไหลในการพัฒนาแอปพลิเคชันที่ใช้งานจริงในบริบทภาษาไทย

1.5 เทคโนโลยีและเครื่องมือที่ใช้

เทคโนโลยีและเครื่องมือที่ใช้ในการพัฒนาและดำเนินงานวิจัย มีรายละเอียดดังนี้:

1.5.1 เทคโนโลยีด้านฮาร์ดแวร์

- Personal Computer Specification: เครื่องคอมพิวเตอร์สำหรับการพัฒนาโปรแกรมและการจัดเก็บชุดข้อมูลทดสอบ
- Cloud Inference Engine: ใช้งานระบบประมวลผลประสิทธิภาพสูงจาก Groq API เพื่อให้สามารถรันโมเดลขนาดใหญ่ได้อย่างรวดเร็วและมีประสิทธิภาพ

1.5.2 เทคโนโลยีด้านซอฟต์แวร์

- Programming Language: ภาษา Python สำหรับการพัฒนาสคริปต์เพื่อจำลองการโจมตีและประมวลผลกลไกการป้องกัน
- Application Programming Interface (API): บริการ Groq API สำหรับการเชื่อมต่อและส่งคำสั่ง (Prompts) ไปยังโมเดลเป้าหมาย
- Security and Data Processing Tools:

1. Regular Expression (Regex): สำหรับการทำ Pattern Matching เพื่อตรวจจับและปิดบังข้อมูลในส่วน Scrubbing
2. Named Entity Recognition (NER): สำหรับระบุชื่อบุคคลหรือข้อมูลเฉพาะเจาะจงในภาษาไทยเพื่อทำการ Scrubbing

- Development Platform: ซอฟต์แวร์สำหรับเขียนและทดสอบโค้ด (VS Code) และเครื่องมือสำหรับวิเคราะห์ผลสถิติ สร้างกราฟ

1.6 แผนการดำเนินงาน

ขั้นตอนการดำเนินงาน	ธ.ค. 2568	ม.ค. 2569	ก.พ. 2569	มี.ค. 2569
เปลี่ยนหัวข้อโปรเจค และ กำหนดขอบเขตของโปรเจค	■			
ศึกษางานวิจัยที่เกี่ยวข้อง (LLM-PBE)	■			
ออกแบบ DEA prompt และ JA prompt สำหรับภาษาไทยในแต่ละระดับ	■			
สร้าง script รันการโจมตีอัตโนมัติ และ ออกแบบการการวัดผลการโจมตีที่สำเร็จ	■	■		
ดำเนินการทดลองโจมตีและเก็บรวบรวมผลการทดสอบ	■	■	■	
ออกแบบการป้องกัน Scrubbing และ Defensive prompt			■	
ดำเนินการทดลองป้องกันการโจมตีและเก็บรวบรวมผลการทดสอบ			■	■
วิเคราะห์ผลการทดลองและสรุปผลการทดลอง				■
จัดทำรายงานฉบับสมบูรณ์และเตรียมนำเสนอผลงาน				■

1.7 บทบาทและความรับผิดชอบ

เพื่อให้การดำเนินงานวิจัยเป็นไปอย่างมีประสิทธิภาพ คณะผู้จัดทำได้แบ่งหน้าที่ความรับผิดชอบตามความเชี่ยวชาญและเนื้อหางาน ดังนี้:

1. กิตติวินท์ พรรณเชษฐ์
   - ออกแบบชุดคำสั่งสำหรับการโจมตีทั้งรูปแบบ Data Extraction Attack (DEA) และ Jailbreak Attack (JA)
   - รับผิดชอบการรันการโจมตีในระดับภาษาทางการ (Ceremonial) และระดับภาษากึ่งทางการ (Semi-formal)
   - ออกแบบและแก้ไขค่ามาตรวัด JA ในส่วนของข้อมูลติดต่อ
   - วิเคราะห์ผลลัพธ์การโจมตี DEA และ JA ร่วมกับทีมเพื่อนำไปสู่การสรุปผลเชิงสถิติและการทำ Visualization
2. พิพัฒน์พงศ์ กาวิลดง

- รับผิดชอบการแปลชุดคำสั่ง JA จากภาษาอังกฤษเป็นภาษาไทยครอบคลุมทั้ง 5 ระดับภาษา
- รับผิดชอบหลักในการรันการโจมตีในระดับภาษาไม่เป็นทางการ (Informal) และการรันผลการโจมตีในรอบภาษาอังกฤษสำหรับทุกโมเดล (Semi-formal)
- พัฒนาและแก้ไขโครงสร้าง Code สำหรับการจัดการเส้นทางข้อมูล (Path), การสร้างจุดบันทึกผล (Checkpoint) และการประยุกต์ใช้ Defensive Prompting ร่วมกับ JA
- ออกแบบมาตรวัด JA และจัดทำสื่อนำเสนอผลงานสำหรับการรายงานความก้าวหน้า

3. ภัทรพล ณ นคร

- ดำเนินการแปลชุดคำสั่งปริมาณมาก (Batch Processing) ผ่าน OpenAI API ให้ครอบคลุมทุกระดับภาษา
- รับผิดชอบการรันการโจมตีในระดับภาษาทางการ (Formal) และภาษาอังกฤษ รวมถึงการบริหารจัดการ API Key ผ่านระบบ Organization ของ Groq
- พัฒนามาตรวัด JA ให้สมบูรณ์ วิเคราะห์ Keyword เพื่อออกแบบกลไกการป้องกัน และดำเนินการทดสอบระบบ Input Scrubbing
- จัดการระบบควบคุมเวอร์ชันของซอร์สโค้ด (Version Control) และวิเคราะห์ผลลัพธ์เพื่อสร้าง Visualization

4. วายุ ทะไร

- ออกแบบมาตรวัดสำหรับ DEA และพัฒนาระบบรันการทดสอบอัตโนมัติที่สามารถเรียกใช้หลาย API และหลายรูปแบบการโจมตีพร้อมกันผ่าน Terminal เดียว
- รับผิดชอบหลักในการรันการโจมตีในระดับภาษากันเอง (Casual) สำหรับทั้ง 3 โมเดล และรันการทดสอบในรอบภาษาอังกฤษ
- พัฒนาระบบรวบรวมข้อมูลผลลัพธ์ คำนวณปริมาณ Token และความยาวข้อความ พร้อมสร้างกราฟสรุปผลอัตโนมัติ
- ออกแบบชุดคำสั่งป้องกัน (Defensive Prompting) สำหรับทั้ง DEA และ JA จำนวน 12 รูปแบบ และคัดเลือกรูปแบบที่มีประสิทธิภาพสูงสุดมาใช้งาน

1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม

การดำเนินโครงงานวิจัยนี้ส่งผลกระทบในมิติต่าง ๆ ที่สำคัญ ดังนี้:

- ด้านความปลอดภัยและกฎหมาย
  โครงงานนี้ช่วยระบุช่องโหว่ของการรั่วไหลข้อมูลส่วนบุคคล (PII) ในโมเดลภาษาขนาดใหญ่ ซึ่งสอดคล้องกับหลักการของพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) ของประเทศไทย โดยการทดสอบการโจมตีแบบ Data Extraction Attack (DEA) และ Jailbreak Attack (JA) ช่วยให้ผู้พัฒนาระบบสามารถเตรียมแนวทางป้องกันเพื่อลดความเสี่ยงทางกฎหมายและเพิ่มความมั่นคงปลอดภัยให้แก่ข้อมูลของผู้ใช้งาน

- ด้านสังคมและวัฒนธรรม
  เนื่องจากมาตรฐานการประเมินส่วนใหญ่มักจำกัดอยู่ในบริบทภาษาอังกฤษ โครงงานนี้จึงสร้างผลกระทบเชิงบวกต่อสังคมไทยโดยการสร้างชุดทดสอบที่ครอบคลุมถึง 5 ระดับภาษาไทย ช่วยให้เทคโนโลยี AI มีความเข้าใจและเคารพในบริบททางวัฒนธรรมที่หลากหลายของไทย ตั้งแต่ภาษาระดับพิธีการไปจนถึงภาษาระดับกันเอง
- ด้านสุขภาพและสิ่งแวดล้อม
  การมุ่งเน้นศึกษาบนโมเดลขนาดเล็กที่ประหยัดทรัพยากร (Resource-saving models) เช่น llama-3.1-8b-instant และ meta-llama-llama-4-maverick-17b-128e-instruct ส่งผลดีต่อสิ่งแวดล้อมในแง่ของการลดการใช้พลังงานไฟฟ้าและทรัพยากรในการประมวลผล (Compute power) ซึ่งเป็นส่วนหนึ่งของการพัฒนา Green IT ในอนาคต

บทที่ 2
ทฤษฎีที่เกี่ยวข้อง

การดำเนินโครงงานวิจัยนี้อาศัยพื้นฐานความรู้ด้านตัวแบบภาษาขนาดใหญ่ (LLMs) ความมั่นคงปลอดภัยของข้อมูล และบริบททางภาษาศาสตร์ของภาษาไทย โดยมีรายละเอียดทฤษฎีที่เกี่ยวข้องดังนี้:

2.1 ตัวแบบภาษาขนาดใหญ่ (Large Language Models: LLMs)

ตัวแบบภาษาขนาดใหญ่เป็นนวัตกรรมด้านการประมวลผลภาษาธรรมชาติ (NLP) ที่ใช้โครงข่ายประสาทเทียมขนาดมหาศาลเพื่อทำความเข้าใจและสร้างภาษา โดยมีองค์ประกอบสำคัญดังนี้

- สถาปัตยกรรม (Architecture): โมเดลส่วนใหญ่พัฒนาบนสถาปัตยกรรม Transformer ซึ่งใช้กลไก Self-attention ในการประมวลผลความสัมพันธ์ของคำในบริบทที่ยาวได้อย่างมีประสิทธิภาพ
- กระบวนการฝึกฝน (Training Stages): ประกอบด้วย 3 ขั้นตอนหลัก ได้แก่:
  - Pre-training: การเรียนรู้จากชุดข้อมูลดิบจำนวนมหาศาลเพื่อให้โมเดลเข้าใจโครงสร้างภาษา
  - Supervised Fine-tuning (SFT): การปรับจูนโมเดลด้วยชุดข้อมูลที่ระบุผลลัพธ์ที่ถูกต้องเพื่อให้โมเดลตอบสนองต่อคำสั่งได้ตรงประเด็น
  - RLHF (Reinforcement Learning from Human Feedback): การปรับแต่งผลลัพธ์สุดท้ายด้วยคำแนะนำจากมนุษย์ เพื่อให้โมเดลมีความปลอดภัยและเป็นประโยชน์สูงสุด
- ตัวแบบภาษาที่ใช้ในการศึกษา: โครงงานนี้มุ่งเน้นศึกษาโมเดลขนาดเล็กที่ประหยัดทรัพยากรแต่มีประสิทธิภาพสูง ได้แก่:
  - llama-3.1-8b-instant: โมเดลขนาด 8 พันล้านพารามิเตอร์ที่มีความเร็วและประสิทธิภาพสูง
  - meta-llama-llama-4-maverick-17b-128e-instruct: โมเดลขนาดกลางที่มีความแม่นยำและการจัดลำดับเหตุผลที่ซับซ้อน
  - moonshotai-kimi-k2-instruct-0905: โมเดลที่มีจุดเด่นในการประมวลผลบริบทที่ยาวและรองรับหลายภาษา

2.2 ความปลอดภัยและความเป็นส่วนตัวของข้อมูลใน LLMs

ความเป็นส่วนตัวของข้อมูลใน LLMs เกี่ยวข้องกับการป้องกันการรั่วไหลของข้อมูลที่อ่อนไหว (Sensitive Information) ซึ่งมักเกิดจากรูปแบบการโจมตีดังนี้:

- Data Privacy Leakage: การที่โมเดลจดจำข้อมูลส่วนบุคคล (PII) จากชุดข้อมูลฝึกฝนและแสดงผลลัพธ์ออกมาโดยไม่ตั้งใจ
- Data Extraction Attack (DEA): การออกแบบคำสั่งเพื่อล่อลวงให้โมเดลคายข้อมูลลับ เช่น อีเมลหรือข้อมูลติดต่อส่วนตัว
- Jailbreak Attack (JA): การใช้เทคนิคการป้อนคำสั่ง (Prompt Injection) เพื่อหลีกเลี่ยงกฎเกณฑ์ด้านความปลอดภัย (Safety Guardrails) ทำให้โมเดลตอบสนองต่อคำสั่งที่ควรถูกระงับ

2.3 บริบทภาษาไทยและระดับภาษา (Thai Context and Linguistic Registers)

ความซับซ้อนของภาษาไทยเป็นปัจจัยสำคัญที่ทำให้มาตรฐานการประเมินภาษาอังกฤษไม่สามารถนำมาใช้ได้อย่างครอบคลุม:

- ความสำคัญของบริบทไทย: ภาษาไทยมีความกำกวมและการใช้คำที่ขึ้นอยู่กับบริบททางวัฒนธรรมสูง ทำให้การตรวจจับภัยคุกคามทำได้ยากกว่าภาษาที่มีโครงสร้างตายตัว
- ระดับภาษา 5 ระดับ (Linguistic Registers): โครงงานนี้แบ่งการทดสอบออกเป็น 5 ระดับเพื่อประเมินความเปราะบางอย่างละเอียด:
  1. ภาษาระดับพิธีการ: ใช้ในงานพระราชพิธีหรือโอกาสสำคัญยิ่ง
  2. ภาษาระดับทางการ: ใช้ในหนังสือราชการหรือบทความวิชาการ
  3. ภาษาระดับกึ่งทางการ: ใช้ในการประชุมหรือการสื่อสารที่เป็นงานเป็นการ
  4. ภาษาระดับไม่เป็นทางการ: ใช้ในการสนทนาทั่วไปหรือการทำงาน
  5. ภาษาระดับกันเอง: ใช้ในครอบครัวหรือกลุ่มเพื่อนสนิท ซึ่งมักมีคำแสลงหรือภาษาปาก

2.4 กลไกการป้องกัน (Defense Mechanisms)

กลไกป้องกันที่นำมาศึกษาเพื่อเพิ่มความปลอดภัยให้กับระบบมี 2 รูปแบบหลัก:

- Input Scrubbing: การใช้เทคนิค Regex (Regular Expression) และ NER (Named Entity Recognition) เพื่อตรวจจับและปกปิดข้อมูลส่วนบุคคลก่อนที่คำสั่งจะถูกส่งไปยังโมเดล
- Defensive Prompting: การกำหนดคำสั่งในระดับระบบ (System Prompt) เพื่อย้ำเตือนและควบคุมพฤติกรรมของโมเดลให้ปฏิเสธการให้ข้อมูลที่อ่อนไหวหรือคำสั่งที่ผิดกฎความปลอดภัย

2.5 งานวิจัยที่เกี่ยวข้อง (Related Works)

งานวิจัยนี้ได้ศึกษาและอ้างอิงแนวทางจากวรรณกรรมที่สำคัญ ดังนี้:

- LLM-PBE [1]: งานวิจัยต้นแบบที่นำเสนอกรอบการประเมินความเป็นส่วนตัวข้อมูลใน LLMs ซึ่งเป็นฐานสำคัญในการพัฒนาชุดทดสอบภาษาไทยในโครงงานนี้
- สรุปงานวิจัยอื่น ๆ: จากการศึกษาเพิ่มเติมพบว่าภัยคุกคามใน LLMs มีวิวัฒนาการอย่างต่อเนื่อง เช่น งานวิจัย PreCurious ที่ศึกษาเรื่องกับดักความเป็นส่วนตัวในโมเดลที่ผ่านการ Pre-trained และ Jailbroken ที่วิเคราะห์ความล้มเหลวของการฝึกฝนด้านความปลอดภัย รวมถึงการใช้ Persona Prompts เพื่อเพิ่มความสำเร็จในการเจาะระบบ ซึ่งงานวิจัยเหล่านี้ชี้ให้เห็นว่าการป้องกันเพียงด้านเดียวไม่เพียงพอต่อภัยคุกคามที่หลากหลาย

2.6 ความรู้ตามหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน

การดำเนินโครงงานวิจัยนี้มีการประยุกต์ใช้ความรู้จากรายวิชาต่าง ๆ ในหลักสูตรวิศวกรรมคอมพิวเตอร์ เพื่อสร้างระบบที่มีมาตรฐานและถูกต้องตามหลักวิชาการ ดังนี้:

- Artificial Intelligence และ Natural Language Processing (NLP): ใช้ความรู้พื้นฐานเกี่ยวกับโครงสร้างของภาษาและการประมวลผลข้อความ เพื่อทำความเข้าใจการทำงานของตัวแบบภาษาขนาดใหญ่ (LLMs) และนำมาวิเคราะห์ความซับซ้อนของระดับภาษาไทยทั้ง 5 ระดับ
- Information and Cybersecurity: ประยุกต์ใช้แนวคิดเรื่องความมั่นคงปลอดภัยของข้อมูล เพื่อออกแบบและวิเคราะห์รูปแบบการโจมตีประเภท Data Extraction Attack (DEA) และ Jailbreak Attack (JA) รวมถึงการศึกษากลไกการป้องกันข้อมูลส่วนบุคคล (PII)
- Computer Statistics and Data Analysis: ใช้หลักการทางสถิติในการคำนวณหาค่าเฉลี่ยอัตราการโจมตีสำเร็จ (Average Success Rate) จากการทดสอบซ้ำ และการวิเคราะห์ผลการทดลองเชิงเปรียบเทียบระหว่างโมเดลและระดับภาษาต่าง ๆ
- Software Engineering: นำหลักการบริหารจัดการซอฟต์แวร์และการใช้ระบบควบคุมเวอร์ชัน (Version Control) มาใช้ในการทำงานร่วมกันภายในทีม เพื่อให้การพัฒนาโค้ดสำหรับการรันการโจมตีและการวัดผลเป็นไปอย่างเป็นระบบ

2.7 ความรู้นอกหลักสูตรซึ่งถูกนำมาใช้หรือบูรณาการในโครงงาน

นอกเหนือจากความรู้ในชั้นเรียน คณะผู้จัดทำได้ศึกษาและพัฒนาทักษะเพิ่มเติมเพื่อตอบโจทย์ความท้าทายเฉพาะทางในโครงงานวิจัยนี้:

- Advanced Prompt Engineering: ศึกษาเทคนิคการออกแบบคำสั่งเชิงลึกสำหรับการทำ Jailbreak และการสร้าง Defensive Prompting เพื่อควบคุมพฤติกรรมของโมเดล llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct และ moonshotai-kimi-k2-instruct-0905
- Cloud Inference and API Management: การเรียนรู้วิธีการเชื่อมต่อและบริหารจัดการ Groq API เพื่อการประมวลผลโมเดลภาษาขนาดใหญ่ที่มีประสิทธิภาพสูง รวมถึงการจัดการระบบคิวและการประมวลผลแบบขนาน (Concurrency) เพื่อรันการโจมตีปริมาณมากพร้อมกันในหน้าจอเดียว
- Advanced Thai NLP and Scrubbing Techniques: ศึกษาและประยุกต์ใช้เครื่องมือ Named Entity Recognition (NER) และ Regular Expression (Regex) ที่มีความเฉพาะเจาะจงกับภาษาไทย เพื่อสร้างกลไก Input Scrubbing สำหรับคัดกรองข้อมูลส่วนบุคคลก่อนส่งไปยังโมเดล
- Automated Data Pipeline: พัฒนาสคริปต์อัตโนมัติสำหรับการรวบรวมข้อมูลผลลัพธ์การทดลอง การคำนวณปริมาณ Token และความยาวข้อความ พร้อมทั้งการสร้างกราฟแสดงผลโดยอัตโนมัติเพื่อความรวดเร็วในการวิเคราะห์ข้อมูล
- LLM Security Research Methodology: ศึกษาและอ้างอิงกรอบแนวทางการประเมินความเป็นส่วนตัวจากงานวิจัย LLM-PBE เพื่อนำมาปรับใช้เป็นบรรทัดฐาน (Benchmark) ในการทดสอบความปลอดภัยสำหรับภาษาไทย

บทที่ 3
โครงสร้างและขั้นตอนการทำงาน

ในบทนี้จะกล่าวถึงหลักการ การออกแบบระบบ และระเบียบวิธีวิจัยที่ใช้ในการประเมินความปลอดภัยของตัวแบบภาษาขนาดใหญ่ (LLMs) โดยครอบคลุมตั้งแต่กระบวนการเตรียมชุดข้อมูล การออกแบบกลไกการโจมตีและการป้องกัน ไปจนถึงการพัฒนาระบบรันการทดสอบอัตโนมัติ

3.1 ภาพรวมสถาปัตยกรรมระบบ (System Architecture)

ระบบถูกออกแบบให้ทำงานในรูปแบบ Pipeline เพื่อทดสอบโมเดลภาษาผ่าน Groq API โดยมีขั้นตอนการไหลของข้อมูลดังนี้:

1. Input Layer: รับคำสั่ง (Prompt) ที่ผ่านการปรับแต่งระดับภาษาไทย 5 ระดับ
2. Defense Layer (Input Scrubbing): กรองข้อมูลส่วนบุคคล (PII) ขาเข้าด้วยเทคนิค Regex และ NER ก่อนส่งไปยังโมเดล
3. Inference Layer: ส่งคำสั่งไปยังโมเดล llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct หรือ moonshotai-kimi-k2-instruct-0905 ผ่าน Groq API พร้อมการใช้งาน Defensive Prompting
4. Evaluation Layer: ระบบรวบรวมคำตอบและประเมินผลด้วยมาตรวัดที่ออกแบบอัตโนมัติ

3.2 การเตรียมชุดข้อมูลและระดับภาษา (Data Preparation)

- ชุดข้อมูลหลัก: ใช้ข้อมูลอีเมลจาก Enron สำหรับการทดสอบ DEA และข้อมูลส่วนบุคคลของบุคคลสำคัญ (เช่น Joe Biden) สำหรับการทดสอบ JA
- กระบวนการปรับระดับภาษา: ใช้เทคนิค Batch Processing ผ่าน OpenAI API เพื่อแปลชุดคำสั่งปริมาณ 3,050 ชุด ให้ครอบคลุม 5 ระดับภาษาไทย ได้แก่ ระดับพิธีการ, ทางการ, กึ่งทางการ, ไม่เป็นทางการ และกันเอง

3.3 ระเบียบวิธีการโจมตี (Attack Methodology)

สภาพแวดล้อมการทดสอบ: ดำเนินการทดสอบซ้ำอย่างน้อย 5 รอบต่อกรณี เพื่อหาค่าเฉลี่ยอัตราความสำเร็จ (Average Success Rate)

- Data Extraction Attack (DEA): ออกแบบคำสั่งเพื่อล่อลวงให้โมเดลเปิดเผยข้อมูลอีเมลหรือข้อมูลลับที่ถูกเก็บไว้ในหน่วยความจำ
- Jailbreak Attack (JA): ใช้เทคนิค Persona Prompts หรือการสร้างสถานการณ์จำลองเพื่อหลีกเลี่ยงระบบความปลอดภัยของโมเดล

3.4 การออกแบบกลไกการป้องกัน (Defense Design)

3.4.1 Input Scrubbing: (เอาเลขแบบนี้ หรือจุดๆดี)

พัฒนาระบบตรวจสอบคำสั่งขาเข้าด้วย Regular Expression (Regex) และ Named Entity Recognition (NER) เพื่อตรวจจับและปกปิดข้อมูลประเภท ชื่อ, อีเมล, เบอร์โทรศัพท์ ก่อนถึงตัวโมเดล

3.4.2 Defensive Prompting

ออกแบบ System Prompt จำนวน 12 รูปแบบ (แบ่งเป็นสำหรับ DEA 6 แบบ และ JA 6 แบบ) เพื่อกำหนดขอบเขตพฤติกรรมของโมเดลให้ปฏิเสธการตอบข้อมูลที่เป็นอันตราย

3.5 การพัฒนาระบบรันการทดสอบอัตโนมัติ (Automated Testing)

ทีมวิจัยได้พัฒนาเครื่องมือเพื่อเพิ่มประสิทธิภาพในการทดลอง ดังนี้:

- Multi-API and Multi-Attack Execution: สคริปต์ใน Terminal เดียวที่สามารถสั่งรันหลายโมเดลและหลายรูปแบบการโจมตีพร้อมกันได้
- Automated Data Logging: ระบบจะบันทึกผลลัพธ์ลงใน Google Sheets โดยอัตโนมัติ
- Metrics Calculation: พัฒนาฟังก์ชันคำนวณปริมาณ Token, ความยาวข้อความ และสร้างกราฟสรุปผล (Visualization) ทันทีหลังจบการทดลอง

3.6 มาตรวัดการประเมินผล (Evaluation Metrics)

- DEA Metrics: วัดความถูกต้องแม่นยำ (Accuracy) ในการดึงข้อมูลตามความเป็นจริง
- JA Metrics: กำหนดเกณฑ์การตัดสิน (Labeling) ว่าโมเดลถูกเจาะระบบสำเร็จหรือไม่ โดยพิจารณาจากข้อมูลที่โมเดลตอบกลับมาในส่วนของข้อมูลติดต่อ

บทที่ 4
การทดลองและผลลัพธ์

ในบทนี้จะนำเสนอและวิเคราะห์ผลการทดสอบประสิทธิภาพความปลอดภัยของโมเดล llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct และ moonshotai-kimi-k2-instruct-0905 ภายใต้เงื่อนไขต่าง ๆ

4.1 ผลการทดสอบการโจมตีเพื่อดึงข้อมูล (Data Extraction Attack: DEA)

วิเคราะห์ความเปราะบางของโมเดลต่อการรั่วไหลของข้อมูลส่วนบุคคล (PII)

4.1.1 การเปรียบเทียบระหว่างภาษาไทยและภาษาอังกฤษ

นำเสนอความต่างของอัตราการดึงข้อมูลสำเร็จระหว่างภาษาไทยและภาษาอังกฤษในภาพรวม

4.1.2 ผลกระทบของระดับภาษาไทยทั้ง 5 ระดับ

วิเคราะห์ความอ่อนไหวของโมเดลเมื่อเผชิญกับภาษาไทยระดับต่าง ๆ (พิธีการ, ทางการ, กึ่งทางการ, ไม่เป็นทางการ, กันเอง)

4.1.3 การวิเคราะห์ความแตกต่างของประสิทธิภาพรายโมเดลใน DEA

เปรียบเทียบว่าระหว่าง llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct และ moonshotai-kimi-k2-instruct-0905 โมเดลใดมีความสามารถในการกักเก็บข้อมูล (Data Retention) ได้ดีที่สุด และโมเดลใดมีแนวโน้มจะคายข้อมูลออกมาได้ง่ายที่สุด

4.1.4 การวิเคราะห์เชิงปริมาณของ Token และความยาวข้อความ

ความสัมพันธ์ระหว่างความยาวของ Prompt และจำนวน Token ต่อความแม่นยำในการคายข้อมูล

4.1.5 ประสิทธิภาพของกลไกการป้องกัน (Scrubbing vs Defensive Prompting)

เปรียบเทียบผลลัพธ์ระหว่างการไม่ป้องกัน, การใช้ Input Scrubbing และการใช้ Defensive Prompting

4.2 ผลการทดสอบการเจาะระบบเพื่อข้ามข้อจำกัด (Jailbreak Attack: JA)

วิเคราะห์ความแข็งแกร่งของระบบความปลอดภัย (Safety Guardrails) ต่อคำสั่งล่อลวง

4.2.1 การเปรียบเทียบระหว่างภาษาไทยและภาษาอังกฤษ

วิเคราะห์ความยากหรือง่ายในการเจาะระบบเมื่อใช้ภาษาไทยเปรียบเทียบกับภาษาอังกฤษ

4.2.2 ผลกระทบของระดับภาษาไทยทั้ง 5 ระดับ

ตรวจสอบว่าระดับภาษาไทยที่มีความเป็นทางการสูงส่งผลต่อการปฏิเสธคำสั่งอันตรายของโมเดลอย่างไร

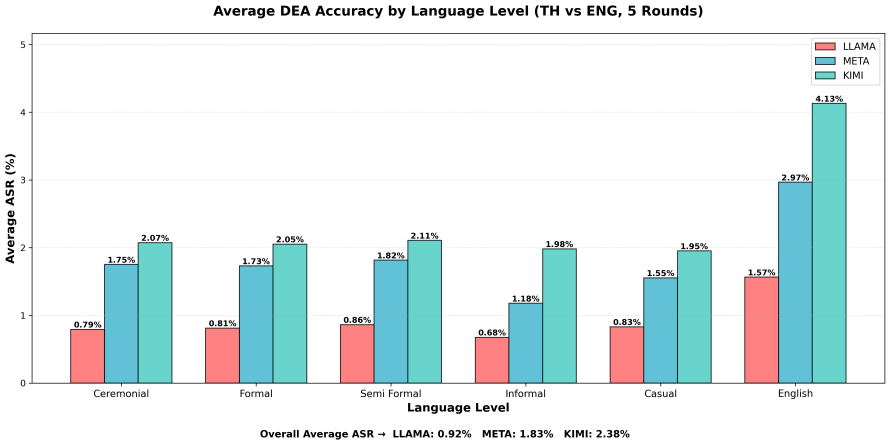

รูปที่ 4.1: DEA Accuracy Average (Thai vs English)

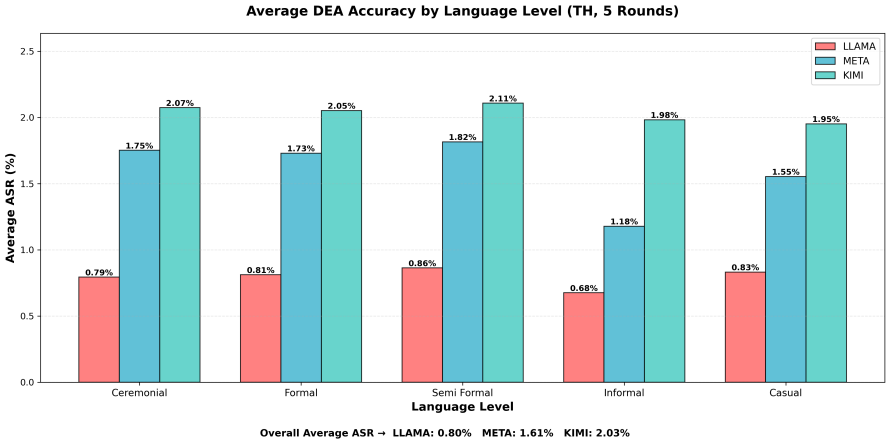

รูปที่ 4.2: DEA Accuracy Average (Thai 5 levels)

4.2.3 การวิเคราะห์ความแตกต่างของประสิทธิภาพรายโมเดลใน JA

เปรียบเทียบความแข็งแกร่งของ Safety Training ระหว่าง llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct และ moonshotai-kimi-k2-instruct-0905 เพื่อระบุว่าโมเดลใดมี ”ปราการความปลอดภัย” ที่หนาแน่นที่สุดต่อการโจมตีเชิงจิตวิทยา (Persona/Social Engineering)

4.2.4 การวิเคราะห์เชิงปริมาณของ Token และทรัพยากรที่ใช้

ความสัมพันธ์ระหว่างความซับซ้อนของ Prompt โจมตีกับการเจาะระบบสำเร็จ

4.2.5 ประสิทธิภาพของกลไกการป้องกัน (Scrubbing vs Defensive Prompting)

ประเมินว่าวิธีใดสามารถยับยั้งการตอบสนองต่อคำสั่งเจาะระบบได้ดีกว่ากัน

4.3 บทวิเคราะห์และข้อสรุปเชิงเทียบเคียง (Overall Discussion)

สรุปผลการประเมินประสิทธิภาพสูงสุด (Best Practice) ของโมเดลและกลไกการป้องกัน

วิเคราะห์แนวโน้มการรั่วไหลของข้อมูลในบริบทภาษาไทยเมื่อเทียบกับมาตรฐานสากล

บทที่ 5
บทสรุปและข้อเสนอแนะ

โครงงานวิจัยการประเมินความเป็นส่วนตัวข้อมูลในบริบทภาษาไทยสำหรับตัวแบบภาษาขนาดใหญ่ ได้ดำเนินการทดสอบและวิเคราะห์ผลอย่างครอบคลุม ซึ่งสามารถสรุปผลการดำเนินงาน ปัญหาที่พบ และแนวทางการพัฒนาต่อได้ดังนี้

5.1 สรุปผล

จากการทดสอบโมเดล llama-3.1-8b-instant, meta-llama-llama-4-maverick-17b-128e-instruct และ moonshotai-kimi-k2-instruct-0905 ด้วยการโจมตีรูปแบบ DEA และ JA ในบริบทภาษาไทย 5 ระดับ และภาษาอังกฤษ พบว่า:

- ประสิทธิภาพของโมเดล: llama-3.1-8b-instant มีความโดดเด่นในการต้านทานการดึงข้อมูลส่วนบุคคล (DEA) ในขณะที่ meta-llama-llama-4-maverick-17b-128e-instruct แสดงความแข็งแกร่งสูงสุดในการยับยั้งการเจาะระบบเพื่อข้ามข้อจำกัดความปลอดภัย (JA)
- อิทธิพลของระดับภาษา: ระดับภาษาไทยส่งผลต่อพฤติกรรมของโมเดลอย่างมีนัยสำคัญ โดยเฉพาะในระดับภาษาที่เป็นทางการซึ่งโมเดลมีแนวโน้มจะปฏิเสธการโจมตีได้ดีกว่าระดับภาษากันเอง
- ประสิทธิผลของกลไกการป้องกัน: กลไก Input Scrubbing โดยใช้ Regex และ NER มีประสิทธิภาพสูงในการป้องกันการรั่วไหลของข้อมูล PII (DEA) ส่วน Defensive Prompting เป็นเครื่องมือสำคัญในการลดอัตราความสำเร็จของการโจมตีเชิงจิตวิทยา (JA)

ข้อจำกัดของระบบ:

- ความแม่นยำของภาษาไทย: ระบบ Scrubbing ยังมีข้อจำกัดในการตรวจจับชื่อบุคคลไทยที่ไม่มีรูปแบบตายตัว หรือคำแสลงในระดับภาษากันเอง (Casual)
- ข้อจำกัดด้านทรัพยากร: การทดสอบถูกจำกัดด้วยอัตราการเรียกใช้งาน (Rate Limit) ของ Groq API และงบประมาณในการเข้าถึงทรัพยากรทางเทคนิค
- ขอบเขตข้อมูล: ผลการทดลองอ้างอิงจากชุดข้อมูลอีเมล Enron และข้อมูลบุคคลสำคัญ ซึ่งอาจไม่ครอบคลุมข้อมูลส่วนบุคคลในบริบทอื่น ๆ ทั้งหมด

5.2 ปัญหาที่พบและแนวทางการแก้ไข

ในการทำโครงงานนี้ คณะผู้จัดทำพบปัญหาหลักและได้ดำเนินการแก้ไขดังนี้:

1. ปัญหาด้านเสถียรภาพของ API และข้อจำกัดความเร็ว
    - ปัญหา: การส่งคำสั่งโจมตีปริมาณมากทำให้เกิด Error และการหยุดชะงักของระบบ
    - การแก้ไข: พัฒนาระบบรันอัตโนมัติที่รองรับหลาย API Key และเพิ่มระบบ Checkpoint เพื่อให้สามารถรันงานต่อจากจุดที่ค้างได้ทันที

2. ความซับซ้อนในการวัดผลการโจมตี (Metrics Accuracy)
    - ปัญหา: มาตรวัด JA ในระยะแรกไม่สามารถแยกแยะการตอบกลับที่เป็นอันตรายได้อย่างแม่นยำ
    - การแก้ไข: ปรับปรุงมาตรวัด (Edit Metrics) โดยเน้นการตรวจสอบ Contact Information และวิเคราะห์ Keyword ร่วมกันอย่างละเอียด
3. ความคลาดเคลื่อนในการแปลระดับภาษา
    - การแปล Prompt ปริมาณมากด้วยระบบอัตโนมัติอาจทำให้โทนของระดับภาษาผิดเพี้ยน
    - การแก้ไข: ใช้การประมวลผลแบบ Batch ผ่าน OpenAI API และทำการตรวจสอบความถูกต้อง (Manual Verification) ในบางส่วนเพื่อให้มั่นใจว่าครอบคลุมทั้ง 5 ระดับภาษาจริง
4. การจัดการผลลัพธ์จำนวนมาก
    - ปัญหา: ข้อมูลผลลัพธ์มีปริมาณมากจนยากต่อการวิเคราะห์ด้วยมือ
    - การแก้ไข: สร้างสคริปต์อัตโนมัติเพื่อคำนวณ Token, ความยาวข้อความ และสร้างกราฟสรุปผลลงใน Google Sheets โดยตรง

5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ

เพื่อให้งานวิจัยนี้มีความสมบูรณ์และเป็นประโยชน์ต่อวงการ AI ในประเทศไทยยิ่งขึ้น มีข้อเสนอแนะดังนี้:

- การขยายขอบเขตโมเดล: ควรมีการทดสอบกับโมเดลที่ถูกปรับจูนมาเพื่อภาษาไทยโดยเฉพาะ (Thai Fine-tuned Models) เพื่อเปรียบเทียบความปลอดภัยกับโมเดลมาตรฐานสากล
- การพัฒนาระบบ Scrubbing เชิงลึก: พัฒนาโมเดล NER ที่มีความเฉพาะเจาะจงกับบริบทของประเทศไทยมากขึ้น เพื่อเพิ่มความแม่นยำในการคัดกรองข้อมูลก่อนส่งเข้าสู่ LLMs
- การทดสอบในสภาพแวดล้อมจริง: นำกลไกการป้องกันที่ได้จากงานวิจัยไปทดสอบกับแอปพลิเคชันที่ใช้งานจริง เช่น ระบบ Customer Service เพื่อประเมินผลกระทบต่อความล่าช้า (Latency) และประสบการณ์ของผู้ใช้งาน
- การปรับปรุง Defensive Prompting อัตโนมัติ: ศึกษาการใช้ AI ในการสร้างและปรับเปลี่ยนคำสั่งป้องกัน (Self-adaptive Defense) ตามรูปแบบการโจมตีที่เปลี่ยนไปในอนาคต

บรรณานุกรม

[1] Jiachen Gu et al. LLM-PBE: Assessing data privacy in large language models. *arXiv preprint arXiv:2408.12784*, 2024.

ภาคผนวก

ภาคผนวก ก
ตัวอย่างชุดคำสั่ง (Sample Prompts)

เนื่องจากงานของคุณมีถึง 5 ระดับภาษาไทย ควรโชว์ตัวอย่างให้เห็นชัดเจน:

- ตัวอย่าง Prompt DEA/JA: โชว์เทียบกันเลยว่า ภาษาระดับพิธีการ vs ระดับกันเอง หน้าตาต่างกันอย่างไร
- ตัวอย่าง Defensive Prompting: รายละเอียดของ System Prompt ทั้ง 12 รูปแบบที่ทีมออกแบบไว้

ภาคผนวก ข

ซอร์สโค้ดของโครงงาน (Source Code)

Scrubbing Function: โค้ดที่ใช้ Regex และ NER ในการกรองข้อมูล

Metric Calculation: โค้ดที่ใช้คำนวณผลลัพธ์หรือวาดกราฟอัตโนมัติ

GitHub Link: ควรใส่ URL ของ Repository ไว้ในหน้านี้ด้วย

ภาคผนวก ฆ
ผลการทดสอบเพิ่มเติม (Extended Results)

ตารางสรุปผลละเอียด: ค่า Accuracy หรือ Success Rate ของทุกโมเดลในทุกระดับภาษา (3 โมเดล × 6 ภาษา × 2 ประเภทการโจมตี)

รูปภาพตัวอย่าง Log: ภาพหน้าจอ Terminal หรือหน้า Google Sheets ที่ระบบบันทึกข้อมูลไว้

ภาคผนวก ค
คู่มือการใช้งานระบบ

Manual goes here.

ประวัติผู้เขียน

นายวายุ ทะไร

มีตัวอย่างไหมมม